

## Capítulo 3

# Kriging Ordinario

Kriging Ordinario es similar a Kriging Simple y sólo se diferencia en el hecho que la media del proceso,  $E(z_j) = \mu$ , es constante pero desconocida y deberá ser estimada. La estimación de  $\mu$  también se construye a partir de una combinación lineal de la muestra; además, como  $\hat{\mu}$  es un estimador se determinará su varianza para poder hacer inferencia acerca del verdadero valor de  $\mu$ .

Se sugiere ver previamente los Capítulos I y II (Kriging Simple) ya que la notación y los resultados allí presentados se usan en este capítulo.

### 3.1. Objetivos de Kriging Ordinario

Dada la muestra  $A = \{(z_1, x_1), \dots (z_j, x_j), \dots (z_n, x_n)\}$  del campo aleatorio en el espacio  $R^p$ , es decir:  $z_1, \dots, z_j, \dots, z_n$  las variables aleatorias definidas en los puntos  $x_1, \dots, x_j, \dots, x_n$  del campo en consideración, y asumiendo como hipótesis que:

- El proceso es estacionario de segundo orden
- Su estructura de covarianza es conocida
- La media del proceso,  $E(z_j) = \mu$ , es desconocida

Kriging Ordinario persigue los siguientes objetivos:

1. Construir un estimador **lineal insesgado**  $\hat{\mu}$  de  $\mu$  de **varianza mínima (BLUE)**, y determinar dicha varianza con la finalidad de hacer inferencia sobre el verdadero valor de la media  $\mu$ .
2. Dada la muestra  $A$  y punto arbitrario  $x_0$ , donde se desconoce  $z_0$ , construir un predictor **lineal insesgado**  $\hat{z}_0$  de  $z_0$  de modo de **minimizar la varianza del error (BLUP)**, donde se entiende por *error* la variable aleatoria  $error = z_0 - \hat{z}_0$ , diferencia entre  $z_0$  y el predictor  $\hat{z}_0$ . Además, determinar dicha varianza.

### 3.2. ESTIMACIÓN DE LA MEDIA $\mu$ DEL PROCESO Y SU VARIANZA

---

Nótese que tanto  $\hat{z}_0$  como *error* son predictores, es decir variables aleatorias!! Sólo cuando se toma una muestra y  $z_1, \dots, z_j, \dots, z_n$  son valores muestrales específicos de una realización, Kriging Simple genera un mapa de predicción de la realización y otro de la varianza del error. Los resultados que siguen corresponden a propiedades de las variables aleatorias, es decir antes del proceso de tomar valores específicos de  $z_1, \dots, z_j, \dots, z_n$ .

## 3.2. Estimación de la media $\mu$ del proceso y su varianza

### 3.2.1. Estimación de la media $\mu$

La siguiente proposición establece que el estimador óptimo de la media  $\mu$  del proceso depende de la posición relativa de los puntos de la muestra, información contenida en la matriz  $C$  de covarianza.

#### Proposición

El estimador lineal insesgado óptimo  $\hat{\mu}$  es un promedio ponderado de los valores de la muestra:

$$\hat{\mu} = \beta^T Z \quad \text{con} \quad \bar{\beta} = \frac{\text{inv}(C) L}{L^T \text{inv}(C) L} \quad (3.1)$$

Siendo la varianza mínima del error

$$\text{Var}(\hat{\mu}) = \text{Var}(\hat{\beta}^T Z) = \frac{1}{L^T \text{inv}(C) L} \quad (3.2)$$

#### Demostración:

▼Se construye un estimador lineal de  $\mu$ ,  $(\beta^T Z)$ , que sea insesgado y de varianza mínima. Si es insesgado se cumple:

$$E(\beta^T Z) = \beta^T E(Z) = \beta^T \mu L = \mu, \text{ luego}$$

$$\beta^T L = 1 \quad (3.3)$$

La suma de los  $\beta_j$  debe ser 1. Es decir, un promedio ponderado de  $Z$ .

La varianza del estimador es:  $\text{Var}(\beta^T Z) = \beta^T C \beta$

Su optimización es un problema de minimización con la restricción ecu.3.3, que se resuelve mediante multiplicadores de Lagrange agregando un parámetro  $2\delta$  por la restricción

$$\min H(\beta, \lambda) = \beta^T C \beta + 2\delta (\beta^T L - 1)$$

### 3.2. ESTIMACIÓN DE LA MEDIA $\mu$ DEL PROCESO Y SU VARIANZA

---

donde por comodidad el multiplicador se expresa como  $2\delta$ . Si anulamos los gradientes respecto de las dos variables de la función  $H(\beta, \delta)$  a minimizar :

$$\nabla_{\beta} = 2C\beta + 2\delta L = 0$$

$$\nabla_{\delta} = 2(\beta^T L - 1) = 0$$

de la primera:

$$\beta = -\delta \text{inv}(C)L$$

y multiplicando a la izquierda por  $L^T$  y usando la segunda igualdad:

$$1 = -\delta L \text{inv}(C)L \quad \delta = \frac{-1}{L^T \text{inv}(C)L}$$

entonces:

$$\bar{\beta} = \frac{\text{inv}(C)L}{L^T \text{inv}(C)L}$$

En cuanto a su varianza

$$\text{Var}(\bar{\beta}^T Z) = \bar{\beta}^T C \bar{\beta} = \frac{L^T \text{inv}(C)}{L^T \text{inv}(C)L} C \frac{\text{inv}(C)L}{L^T \text{inv}(C)L} = \frac{1}{L^T \text{inv}(C)L} \blacktriangle$$

#### 3.2.2. Corolarios

**3.2.2.1.**  $\bar{\beta}$  es fijo, independiente del muestreo y dado sólo por la estructura de covarianza,  $\text{Cov}(Z)$ .

Como se ha supuesto que la matriz de covarianza depende de la posición de los  $x_j$ , y para este conjunto  $\{x_1, \dots, x_j, \dots, x_n\}$  la matriz de covarianza  $\text{Cov}(Z)$  es conocida, el estimador  $\bar{\beta}$  no depende de la muestra  $Z$ , es decir es un vector constante.

**3.2.2.2.**  $\hat{\mu}$  es aleatorio ya que es un promedio ponderado de los valores de la muestra  $Z$

Es un promedio ponderado ya que  $L^T \bar{\beta} = \frac{L^T \text{Cov}(Z)^{-1} L}{L^T \text{Cov}(Z)^{-1} L} = 1$

- 3.2.2.3.** Los pesos de  $\bar{\beta}$  dependen de la posición relativa entre los puntos  $x$  y de los parámetros del modelo de covarianza
- 3.2.2.4.**  $Var(\hat{\mu})$  es conocida previa al muestreo y es proporcional a la varianza del proceso.
- 3.2.2.5.** Si las observaciones de la muestra están muy alejadas,  $C = \sigma^2 I_n$ , entonces  $Var(\hat{\mu}) = \frac{\sigma^2}{n}$  y  $\hat{\mu} = m = \frac{L^T Z}{n}$  coinciden con los clásicos de la media muestral.

### 3.3. Predicción de $z_0$ y varianza del error

La proposición que sigue resume las características del predictor (BLUP) de Kriging Ordinario:

primero, que la predicción óptima depende de la estructura de covarianza de la muestra,  $C$ , de la covarianza entre los puntos de la muestra y el punto donde se desea predecir,  $w$  y de la media estimada del proceso  $\hat{\mu}$ ; y segundo, que la varianza del error depende de  $C$ ,  $w$ , de la varianza de la media  $Var(\hat{\mu})$  y de la varianza del proceso,  $\sigma^2$ .

#### Proposición

Los pesos  $\hat{\alpha}$  del predictor lineal óptimo de  $z_0$ ,  $\alpha^T Z$ , están dados por:

$$\hat{\alpha} = \bar{\gamma} + Var(\hat{\mu}) \text{coef inv}(C) L \quad (3.4)$$

o su equivalente sólo en función de  $C$  y  $w$ :

$$\hat{\alpha} = \text{inv}(C)w + \frac{1}{L^T \text{inv}(C) L} (1 - w^T \text{inv}(C) L) \text{inv}(C) L$$

el predictor por:

$$\hat{z}_0 = \hat{\alpha}^T Z = \hat{\mu} + w^T \text{inv}(C) (Z - L\hat{\mu}) \quad (3.5)$$

y respecto del error cometido, la varianza del error está dada por:

$$Var(Error_0) = \sigma^2 - w^T \text{inv}(C)w + Var(\hat{\mu})(1 - w^T \text{inv}(C)L)^2 \quad (3.6)$$

#### Demostración:

▼

Si el predictor es insesgado se cumple que  $E(\alpha^T Z) = E(z_0) = \mu \Leftrightarrow \alpha^T E(Z) = \alpha^T \mu L = \mu \Leftrightarrow \alpha^T L = 1$  es decir un promedio ponderado.

Si  $Error = z_0 - \alpha^T Z$  se desea minimizar la varianza del Error:

$$\text{Min } Var(Error) = \text{Min } Var(z_0 - \alpha^T Z)$$

### 3.3. PREDICCIÓN DE $Z_0$ Y VARIANZA DEL ERROR

---

De nuevo es un problema de minimización con restricciones, cuyo lagrangiano es:

$$\min H(\alpha, \lambda) = \text{Var}(z_0 - \alpha^T Z) + 2\lambda(\alpha^T L - 1)$$

El primer término es:

$$\text{Var}(z_0) + \text{Var}(\alpha^T Z) - 2\text{cov}(z_0, \alpha^T Z) = \text{Var}(z_0) + \alpha^T C \alpha - 2\alpha^T w \quad (3.7)$$

Luego se minimiza:

$$\min H(\alpha, \lambda) = \text{Var}(z_0) + \alpha^T C \alpha - 2\alpha^T w + 2\lambda(\alpha^T L - 1)$$

Si anulamos los gradientes de la función  $H(\alpha, \lambda)$  respecto de  $\alpha$  y  $\lambda$  se tiene :

$$\nabla_{\alpha} = 2C\alpha - 2w + 2\lambda L = 0$$

$$\nabla_{\lambda} = 2(\alpha^T L - 1) = 0$$

quedando el sistema con dos ecuaciones:

$$C\alpha + \lambda L = w \quad (3.8)$$

$$L^T \alpha = 1 \quad (3.9)$$

Este sistema se puede expresar matricialmente:

$$\begin{bmatrix} C & L \\ L^T & 0 \end{bmatrix} \begin{pmatrix} \alpha \\ \lambda \end{pmatrix} = \begin{pmatrix} w \\ 1 \end{pmatrix} \quad (3.10)$$

Para simplificar los cálculos que siguen se notará  $h = (L^T \text{inv}(C) L)^{-1} = \text{Var}(\hat{\mu})$ .

El sistema 3.10 es:

$$\left\{ \begin{array}{l} C\alpha + \lambda L = w \\ L^T \alpha = 1 \end{array} \right\}$$

luego de la primera ecuación  $\alpha + \lambda \text{inv}(C) L = \text{inv}(C) w$ , que multiplicando por  $L^T$  y aplicando la segunda se tiene:

$$1 + \lambda L^T \text{inv}(C) L = L^T \text{inv}(C) w$$

usando 2.4 y despejando:

$$\lambda = h(L^T \hat{\gamma} - 1) \quad (3.11)$$

$$\hat{\alpha} = \bar{\gamma} - \lambda \text{inv}(C) L = \bar{\gamma} + h \text{coef inv}(C) L \quad (3.12)$$

o su equivalente en función de  $\hat{\beta}$  ecu. 3.1

$$\hat{\alpha} = \bar{\gamma} + h \text{coef inv}(C) L = \hat{\beta} + \bar{\gamma} - L^T \bar{\gamma} \hat{\beta} \quad (3.13)$$

Luego, el predictor óptimo de  $z_0$  es:

$$\hat{\alpha}^T Z = \hat{\beta}^T Z + \bar{\gamma}^T (Z - L \hat{\beta}^T Z)$$

### 3.3. PREDICCIÓN DE $Z_0$ Y VARIANZA DEL ERROR

---

y sustituyendo la media del proceso  $\hat{\mu} = \hat{\beta}^T Z$  se obtiene ecu. 3.5.

En cuanto a la varianza del error mínima, se deduce de las ecuaciones 3.7, 3.8 y 3.9:

$$Var(Error) = Var(z_0) - \alpha^T w - \lambda$$

Sustituyendo  $\alpha$  ecu. 3.12 y  $\lambda$  ecu.3.11 se tiene

$$Var(Error) = Var(z_0) - (\bar{\gamma} + h \text{coef} \text{inv}(C) L)^T w + h \text{coef}$$

$$Var(Error) = \sigma^2 - w^T \text{inv}(C) w - h \text{coef} L^T \text{inv}(C) w + h \text{coef}$$

$$Var(Error) = \sigma^2 - w^T \text{inv}(C) w + h \text{coef}^2 \quad (3.14)$$

y sustituyendo  $h$  y  $\text{coef}$  por su valor se obtiene ecu. 3.6▲

#### corolarios

##### 3.3.1. El predictor es similar al de Kriging Simple

Nótese que la predicción ecu. 3.5 es la media del proceso más un promedio ponderado de los desvíos de los valores de  $Z$  respecto de la media  $\hat{\mu}$ . Estos pesos son los mismos obtenidos en Kriging Simple ecu. 2.8.

##### 3.3.2. La varianza del error tiene un término adicional a la expresión de Kriging Simple

Los dos primeros términos de la ecu. 3.6 corresponden a la fórmula de Kriging Simple a la que se le agrega el término positivo:  $Var(\hat{\mu})(1 - w^T \text{inv}(C) L)^2$ , es decir se tiene un incremento en la varianza del error que se deriva de la incertidumbre en el predictor de la media  $\hat{\mu}$ .

##### 3.3.3. El predictor depende de la estructura de correlación

$\hat{z}_0 = \hat{\alpha}^T Z = \text{corr}(z_0, Z)^T R(Z)^{-1} (Z - L\hat{\mu}) + \hat{\mu}$  es decir, los coeficientes de predicción dependen de la estructura de correlación de los puntos de la muestra  $Z$  entre sí, y de la correlación entre la nueva variable  $z_0$  y los puntos de la muestra  $Z$ .

##### 3.3.4. Caso $x_0$ alejado de la muestra (ausencia de información)

Si  $x_0$  está suficientemente alejado como para que  $w = 0$  entonces el modelo predice con la media  $\hat{\mu}$ . En cuanto a la varianza del error:  $Var(Error) = \sigma^2 + Var(\hat{\mu})$ . A diferencia de Kriging Simple la varianza del error puede superar la varianza del proceso!

### 3.4. Solución numérica eficiente

Los resultados establecidos en las proposiciones fundamentales de las secciones 3,2 y 3,3, se obtienen eficientemente usando las ventajas de la solución de sistemas lineales cuando la matriz es definida positiva, como lo son las matrices de covarianza.

**Entrada:**

La muestra  $\{(z_1, x_1), \dots, (z_j, x_j), \dots, (z_n, x_n)\}$  y el punto  $x_o$  donde predecir  $z_o$

La matriz de covarianza  $C$  entre las variables aleatorias de la muestra

El vector de covarianza  $w$  entre las variables de la muestra y  $z_o$

El **algoritmo** es el siguiente:

1. Resolver el sistema  $C aux = L$  (es decir hallar  $aux = inv(C) L$ )
2. Resolver el sistema  $C \bar{\gamma} = w$  (es decir hallar  $\bar{\gamma} = inv(C) w$ )
3. Calcular  $coef = 1 - L^T \bar{\gamma}$
4. Calcular  $h = (L^T aux)^{-1}$  (Varianza de  $\hat{\mu}$ )
5. Calcular  $\hat{\beta} = h aux$
6. Calcular  $\hat{\alpha} = \bar{\gamma} + coef \hat{\beta}$
7. Calcular  $Var(error) = \sigma^2 - w^T \bar{\gamma} + h coef^2$
8. predecir  $\hat{\mu} = \hat{\beta}^T Z$  ( media muestral)
9. predecir  $\hat{z}_o = \hat{\alpha}^T Z$  (predicción del proceso en el punto  $x_o$ )

Nótese

- que los sistemas 1 y 2 se resuelven simultáneamente, y como  $C$  es definida positiva la solución de dichos sistemas es eficiente (Cholesky, por ejemplo)
- que los primeros 7 pasos se realizan previos al muestreo donde se determinan la varianza de  $\hat{\mu}$  y la varianza del error!
- Que los valores de  $z$  obtenidos en el muestreo son sólo necesarios en los pasos 8 y 9 para predecir la media muestral  $\hat{\mu}$  y la predicción  $\hat{z}_o$ .

### 3.5. Kriging es interpolante y la varianza del error es nula en la muestra

Si  $z_o$  coincide con  $z_1$ , entonces  $w$  es la primera columna de  $C$  luego,  $inv(C) w = (1, 0, \dots, 0)^T$ ,  $L^T inv(C) w = 1$  y  $w^T inv(C) w = \sigma^2$  entonces

$$\hat{\alpha} = (1, 0, \dots, 0)^T$$

lo que implica que el predictor  $\hat{\alpha}^T Z = z_1$ , es decir es interpolante ya que el modelo de pronóstico asigna el valor muestral.

En cuanto a la varianza del error de la ec. 3.14:

$$Var(Error) = \sigma^2 - \sigma^2 = 0$$

es decir el modelo predice con exactitud en los puntos de la muestra.

### 3.6. Hipótesis de Normalidad

Si se presupone que para cualquier conjunto  $x_1, \dots, x_j, \dots, x_k$  el vector  $Z$  asociado es normal multivariado es posible expresar las distribuciones de los predictores hallados en este capítulo así como obtener intervalos de confianza, test de hipótesis, etc. Sin embargo, debido a la estimación de  $\mu$ , los predictores de Kriging Ordinario no coinciden con los resultados de la distribución normal multivariada válidos para Kriging Simple.

#### 3.6.1. Distribución de $\hat{\mu}$

Por lo expresado en la estimación de  $\mu$ , Ecu. 3.1,  $\hat{\mu}$  es una combinación lineal de  $Z$  y es insesgado

$$\hat{\mu} = \beta^T Z = \frac{L^T C Z}{L^T C L}$$

de varianza conocida, Ecu. 3.2

$$Var(\hat{\mu}) = Var(\beta^T Z) = \frac{1}{L^T C L}$$

Luego,  $\hat{\mu}$  se distribuye normal  $N(\mu, Var(\mu))$  y es posible obtener intervalos de confianza de la media,  $\mu$ , del proceso a partir de la función inversa de la distribución acumulada de la Normal.

#### 3.6.2. Distribución de $z_0$

En cuanto al predictor de  $z_0$  por la ecu. 3.5  $\hat{z}_0$  es insesgado y es una C. Lineal de  $Z$

$$\hat{z}_0 = \hat{\alpha}^T Z = w^T inv(C) (Z - L\hat{\mu}) + \hat{\mu}$$

donde la varianza del error,  $\hat{z}_0 - z_0$ , es constante:

Luego,  $z_0 - \hat{z}_0$  se distribuye normal  $N(0, Var(Error))$  y es posible obtener intervalos de confianza de  $z_0$ , a partir de la función inversa de la distribución acumulada de la Normal.